

QC-Team

留学作业质检系统·第三周升级汇报

王彩迪·2026年8月25日

这个问题，值不值得做

一份留学作业交上来，最危险的不是错别字——是两类 AI 看不见的红线：

风险	单个 AI 会怎么反应
文献造假：参考文献根本不存在	会幻觉出一篇看起来很真的假文献来附和你
引用漂移：文献是真的，但原文结论和稿件用它支撑的论点方向相反	会顺着你的结论继续写，找不到原文献的矛盾

解法：三个不同厂商的模型交叉核验，把能被程序确定性查证的事从模型手里拿走，交给 Crossref。

一份作业发过来，前后能做到什么

上周能做到：

- 抓出「文献造假」——用 Crossref 核验 DOI，发现杜撰文献直接红灯
- 给出放行结论——三模型分工，结论写到报告里

上周做不到的（局限性）：

- 跑完不知道在哪步停的——没有状态
- 下一环不等上一环干净——没有闸门
- 复核能看见主审答案——不是真盲判
- 结论无法回溯到原始产物——没有证据留痕

这周新增做到了：

- 每一步有灯：谁在做、卡在哪，看一眼就知道
- 前一环没过，后面不能过——不知道过没可过

这周做了什么（四行清单）

升级项	核心变化
五状态机	每个角色有可机械判定的五种状态，不由 Agent 自报
五道闸门	每道必须附 evidence locator，前一道没过后面不动
证据留痕 + 责权利契约	SHA-256 冻结产物、三角色各持 1/2 强核票、产物可回溯才被复用
Claudepot 定时触发	把质检流水线挂成定时任务，不用手动敲命令

状态机是什么（业务解释）

打个比方：工厂流水线指示灯。

每个工位有四块灯——

● 等原料 (BLOCKED) → ● 正在做 (RUNNING) → ● 做好了 (COMPLETED)
↓
● 出问题了 (FAILED) ← 上游卡住，一路亮红灯传下来

哪个灯红了，一眼就知道卡在哪，不用去猜、不用问 agent 「你跑哪了」。

五条状态，全部可机械判定：

- BLOCKED = 依赖文件还没到
- READY = 依赖齐了，可以派发
- RUNNING = 正在跑
- COMPLETED = 子进程 exit 0 且产物字节数 > 0

闸门是什么（业务解释）

打个比方：出国要过五道关，每道必须有前一道的章。

闸门	业务含义
Gate 1 来源	稿件从哪来的，有没有 DIP manifest 记录
Gate 2 基线	稿件有没有被 SHA-256 冻结，防止中途被改
Gate 3 文献证据	每个 DOI 都要有 Crossref 返回结果，有一条空就卡住
Gate 4 双强核	两个不同厂商的模型，关键事实 2/2 一致才算过
Gate 5 放行	八大板块齐全，且 Gate 4 已通过，才出结论

顺序不是流程图，是许可链。上一道没过，后面不能动——这不是效率问题，是正确性问题。

上游 DIP（Dinstinction Intelligence Pipeline，论文打分系统）打完分之后，交由 QC 复核

为什么要这么设计（三个价值点）

① 为什么要不同厂商的模型？

同一个模型跑三遍，盲区依旧。三个不同厂商的模型，各自的幻觉方向不同，交叉才能覆盖漏洞。

② 为什么要证据留痕？

Agent 说的话是元数据，产物才是证据。产物可回溯的角色，才会被下一次运行继续加载——这就是它的「利」。

③ 为什么让 AI 只有提议权？

Claudepot 的 CLI 故意没有 `install` 动词——AI 只能 draft（提议），上膛必须人点。这条不是我们设计的，是工具替我们回答了「机器人的权力边界在哪」。

过程证据 + 截图

测试：16 个单测，全过


覆盖状态跳转、阻断传播、产物篡改检测、事件日志篡改检测、双审隔离。

Claudepot 真实运行：2026-08-25 04:08:38

Crossref: 10.1016/j.example.2016.01.001 → 查无此文献

最终结论：● 红灯，不建议提交，抓出 3 条严重问题

Agent View `claude agents` — Claude Code v2.1.233



Claudepot 触发运行 — 成功 / is error false / stop reason end turn

还没做到的下一步

诚实说三条，不粉饰：

1. legacy `qc.py` 单轮串联：复核能看见主审答案，不是真正的三方盲判
2. 多轮回源闭环：遇分歧反复回原文核实、三回合仍无共识才交人裁决——尚未实现
3. DIP → QC 生产 run：DIP 分数打出来后自动交给 QC 复核——尚未接上

下一步：改造单轮串联为多轮循环，接通 DIP → QC 链路，配 cron 实现无人值守。

GitHub： <https://github.com/wangfeifei-321/qc-team>