

QC-Team

把上一个 agent team 升级成可审计的真实团队

王彩迪 · 2026 年 8 月 25 日

这套片子的一条规矩

自述是元数据，产物才是证据。

凡是本片写「 已完成」的，都能在仓库里找到对应产物或命令输出。

凡是还没跑出来的，标「未完成」，不标 .

1. 解决的是什么真问题

留学作业质检的两个致命风险

- **文献造假** —— 参考文献根本不存在（学生或 AI 杜撰）
单个 AI 复查无效：它会幻觉出看似真实的假文献来附和提问者
- **引用漂移** —— 文献真实存在，但原文结论与稿件拿它支撑的论点方向相反

这两类问题决定一份作业会不会触碰学术诚信红线。

三模型交叉核验

角色	由谁扮演	放行权
qc-conductor 主审	Claude	强核票 1/2
qc-verifier 复核	Codex	强核票 1/2
qc-reporter 整理	MiniMax	无强核票，异议可阻断

选不同厂商的模型是刻意的：同一个模型跑三遍，盲区依旧。

确定性地基：文献真假不交给 AI

```
$ python3 qc.py samples/demo_稿件样例.txt  
[1/1] 核验 10.1016/j.example.2016.01.001 ... 查无此文献!
```

DOI 存在性走 **Crossref 真实 API**，元数据逐字比对。

能被确定性查证的事，必须交给程序而不是模型。

2. 责权利：机器人世界里怎么分

一个 Agent 的一生：五种状态



每个状态的进入条件都写成可机械判定的，例如

COMPLETED = 子进程 exit code 为 0 且产物文件字节数大于 0。

状态由 `qc_evidence.py` 的 `EvidenceRun` 独占写入，不由 Agent 自报。

(legacy qc.py 没有这套状态机, 入口是 scripts/run_audited_qc.py 。)

三条硬规则

1. 硬依赖强制 —— 依赖全部 `COMPLETED` 且产物可读，才允许进入 `RUNNING`
2. 禁止静默绕过 —— 读不到依赖就停下报 `BLOCKED`，不许自己重造一份上游材料
3. 失败必须传播 —— 上游 `FAILED`，下游一律 `BLOCKED`，由编排器安排返工

五道闸门：顺序不是流程图，是许可制

生产编排 `scripts/run_audited_qc.py` 的 `required_gates`，闸门名与代码逐字一致：

闸门	代码名	判据
1 来源	<code>provenance</code>	上游 DIP manifest 存在，或显式声明无上游
2 基线	<code>baseline_integrity</code>	稿件已冻结并记录 SHA-256
3 文献证据	<code>reference_evidence</code>	每个 DOI 都有 Crossref 结果，无一条留空
4 双强核	<code>independent_dual_review</code>	关键事实 2/2 一致，任一方 UNVERIFIED 即不通过
5 放行	<code>release</code>	八个板块齐全，红黄绿灯有对应依据

每道闸门都要附 evidence locator，且文件须在 run 目录下真实存在。闸门 4 不通过，闸

责权利矩阵

Agent	责	权	利（目标函数）
主审	D1-D7 逐维度出结论、带 locator	强核票 1/2	让「未被复核就放行」归零
复核	从原始材料独立重判，不照抄主审	强核票 1/2	让「主审漏判被下游发现」归零
整理	七项机械扫描、综合出唯一报告	异议可立即阻断	让「报告里出现无依据条目」归零

三个角色都没有写文件的权限——产物由编排器落盘，「谁写了什么」才唯一可追溯。

「利」在机器人世界里是什么

不是报酬，是被复用的资格。

产物可回溯、结论可复现的角色，下一次运行才会继续加载它；
反复产出不可核验结论的角色，应当被改写或删除。

3. 这一周改了什么

升级清单：三种状态，不合并成一个

「写下来了」「单元测试验证过」「真实跑过一次」是三件事。

项目	已定义	单测验证	真实运行
正式 Agent 定义 <code>.claude/agents/</code>			
<code>.claude-plugin/plugin.json</code> + <code>CLAUDE.md</code>			
责权利契约（五状态 + 5 闸门 + 矩阵）			待生产 run
证据运行时 SHA-256 封存			仅演示 run
DIP → QC 交接			未完成
Claudepot 触发		—	 2026-08-25 成功

关键一改：角色定义成为单一事实来源

改之前： `roles/01_主审_claude.md` —— 裸 Markdown，不在任何被识别的路径上。

改之后： `.claude/agents/qc-conductor.md` —— 一份文件两处用

- `qc.py` 用 `read_agent()` 剥掉 frontmatter 当角色提示词
- Claude Code 直接把它当 subagent 加载

改行为只改这一份文件， `qc.py` 只负责传递。

4. 运行证据

测试（本次 commit 实测）

```
$ python3 -m unittest discover -s tests  
Ran 16 tests in 0.104s
```

OK

16 个测试覆盖：稿件读取、Agent 定义加载、frontmatter 剥离、非法状态跳转、阻断恢复、完成拒绝、产物篡改、事件日志篡改、DIP 交接、双审隔离。

端到端质检（2026-08-18 那次真实运行）

环节	结果	产物
Crossref 核验	通过	故意植入的假 DOI 被判「查无此文献」
Claude 主审	通过	约 15 KB 的 D1-D7 意见，红灯
Codex 复核	通过	约 7.4 KB 复核意见，指出主审过度表述
MiniMax 整理	通过	约 6.5 KB 最终报告


系统没有把假 DOI「圆过去」，最终报告给红灯「不可提交」。

⚠ 这一次跑的是 legacy `qc.py`：复核拿到的 prompt 里带着主审答案，不是盲判。
真正的首轮独立只在 `scripts/run_audited_qc.py` 里，目前由单元测试验证，尚无生产 run。

Agent View

启动命令是 `claude agents`（功能全名 Agent View，
`/bg` 丢后台、`claude attach <id>` 连回、`claude respawn --all` 唤醒）。

本机 Claude Code v2.1.233，满足 $\geq v2.1.139$ 的要求。



5. 对照上周的高分样本

顾梦婷的作业强在哪

不是页面好看，是一张页面同时给出可核验的硬指标：

run id · 冻结基线 · Agent 流 · 跨厂商模型路由（含 effort 档位）·


9/9 gates · 逐条时间戳 · 产物与 action 统计 · E2E QA PASS

她的面板右上角写着 `Action Integration: NOT_CONNECTED`。

我们现在的位置（如实）

指标	顾梦婷	本项目
闸门	9/9 PASS	5 道已定义，真实生产 run 待完成
状态机	有	有，五状态 + 可机械判定的进入条件
产物哈希封存	未见	有，SHA-256
Action Integration	NOT_CONNECTED	已接通，且真实跑成功一次

Claudepot: 真实跑通了



这一条是修出来的，不是一次就对

版本	结果	原因
v1	失败，退出码 127	<code>~/.local/bin/claude</code> 指向已失效的旧 Cursor 扩展；修复后又被 Bash 权限门阻断
v2	成功	新 Agent 使用受限 prompt，并把权限收成精确 allowlist

v2 的权限只给到：

```
Read, Grep, Glob, Bash(python3 qc.py *), Bash(python3
/Users/wangcaidi/Desktop/qc-team/qc.py *)
```

AI 只有提议权（draft），上膛必须人来点 —— 这一条不是我们设计的，是 Claudepot 写死的：CLI 里根本没有 `install` 这个动词。

这次运行真的产出了东西

reports/_refs_verified.json	Crossref: 10.1016/j.example.2016.01.001 → 查无此 DOI
reports/demo_稿件样例_1主审.md	7.5 KB
reports/demo_稿件样例_2复核.md	5.3 KB
reports/demo_稿件样例_质检报告_2026-08-25_120847.md	5.5 KB

最终报告结论：**红灯，不建议提交。**

抓出 3 条  严重（杜撰 DOI、卷期页与官方目录冲突、引用方向绝对化误用）。

6. 边界与下一步

还没做到的（不粉饰）

- 单轮串联：复核实际已看到主审答案，做不到真正的三方盲判
- 缺多轮回源闭环：遇分歧反复回原文核实、三回合仍无共识才交人裁决 —— 尚未实现

下一步

1. 把「单轮串联」改造成「多轮循环」：主审出结论 → 自我复核 → 与复核就分歧往返 → 逐轮把原始判断与证据落盘
2. 把 DIP 产稿 → QC 质检跑一次真实生产 run
3. 给 Claudepot agent 配上 cron 表达式，做到无人值守

谢谢

GitHub: <https://github.com/wangfeifei-321/qc-team>

```
git clone https://github.com/wangfeifei-321/qc-team.git  
cd qc-team && cp .env.example .env # 填 MiniMax API Key  
python3 qc.py samples/demo_稿件样例.txt
```

本套幻灯片由 Marp CLI 从 presentation/slides.md 渲染。