

# QC-Team

## 把上一个 agent team 升级成可审计的真实团队

王彩迪 · 2026 年 8 月 25 日

本片凡是标  的，都能在仓库里找到对应产物或命令输出；  
还没跑出来的，标「未完成」，不标 .

# 解决的是什么真问题

留学作业质检真正的风险不在错别字，在两处最隐蔽的地方：

- **文献造假** —— 参考文献根本不存在。单个 AI 复查无效，它会幻觉出看似真实的假文献来附和提问者
- **引用漂移** —— 文献真实，但原文结论与稿件拿它支撑的论点方向相反

| 角色              | 由谁扮演    | 放行权        |
|-----------------|---------|------------|
| qc-conductor 主审 | Claude  | 强核票 1/2    |
| qc-verifier 复核  | Codex   | 强核票 1/2    |
| qc-reporter 整理  | MiniMax | 无强核票，异议可阻断 |

选不同厂商的模型是刻意的：同一个模型跑三遍，盲区依旧。

## 责权利之一：一个 Agent 的一生只有五种状态



每个状态的进入条件都写成可机械判定的：

COMPLETED = 子进程 exit code 为 0 且产物文件字节数大于 0。

状态由 `qc_evidence.py` 的 `EvidenceRun` 独占写入，不由 Agent 自报。

三条硬规则：① 依赖全部 COMPLETED 且产物可读才能进 RUNNING ② 读不到依赖就报 BLOCKED，不许自己重造 ③ 上游 FAILED，下游一律 BLOCKED

## 责权利之二：闸门是许可制，「利」是被复用的资格

| 闸门     | 代码名                     | 判据                              |
|--------|-------------------------|---------------------------------|
| 1 来源   | provenance              | 上游 DIP manifest 存在，或显式声明无上游     |
| 2 基线   | baseline_integrity      | 稿件已冻结并记录 SHA-256                |
| 3 文献证据 | reference_evidence      | 每个 DOI 都有 Crossref 结果，无一条留空     |
| 4 双强核  | independent_dual_review | 关键事实 2/2 一致，任一方 UNVERIFIED 即不通过 |
| 5 放行   | release                 | 八个板块齐全，且闸门 4 已通过                |

三个角色都没有写文件的权限，产物由编排器落盘，「谁写了什么」才唯一可追溯。  
「利」不是报酬，是被复用的资格：产物可回溯的角色，下一次运行才会继续加载它。

# 本周升级：定义、单测、实跑不能混为一谈

「写下来了」「单元测试验证过」「真实跑过一次」是三件事。

| 项目                                       | 已定义 | 单测 | 实跑   |
|------------------------------------------|-----|----|------|
| 正式 Agent 定义 <code>.claude/agents/</code> | ✓   | ✓  | ✓    |
| 插件清单 + <code>CLAUDE.md</code>            | ✓   | ✓  | ✓    |
| 责权利契约                                    | ✓   | ✓  | 待生产  |
| 证据运行时与 SHA-256                           | ✓   | ✓  | 仅演示  |
| DIP → QC 交接                              | ✓   | ✓  | 未完成  |
| Claudepot                                | ✓   | —  | ✓ 成功 |

## 运行证据

```
$ python3 -m unittest discover -s tests
Ran 16 tests ... OK
```

16 个测试覆盖：Agent 定义加载、非法状态跳转、阻断恢复、完成拒绝、产物篡改、事件日志篡改、DIP 交接、双审隔离。


**2026-08-25 那次由 Claudepot 触发的真实运行产出：**

```
reports/_refs_verified.json    Crossref: 10.1016/j.example.2016.01.001 → 查无此 DOI
reports/demo_稿件样例_1主审.md / _2复核.md / _质检报告_2026-08-25_120847.md
```

最终报告**红灯**，**不建议提交**：抓出 3 条  严重——杜撰 DOI、卷期页与官方目录冲突、引用方向绝对化误用。

# Agent View

启动命令 `claude agents` (功能全名 Agent View; `/bg` 丢后台、`claude attach` 连回)。本机 Claude Code v2.1.233, 满足  $\geq v2.1.139$ 。



# Claudepot: 真实跑通了

代理

代理

定时与手动的 `claude -p` 运行 · `launchd`

刷新

从模板...

Session Narrator

+ 添加代理

立即运行

编辑

禁用

删除

显示运行记录

QC-Team Trigger v2

qc-team-trigger-v2

已启用

Runs the QC-Team demo pipeline with an exact command allowlist.

cron -

cwd /Users/wangcaidi/Desktop/qc-team

二进制 claude (第一方) · sonnet

权限 default [Read, Grep, Glob, Bash(python3 qc.py \*), Bash(python3 /Users/wangcaidi/Desktop/qc-team/qc.py \*)]

上次运行于 3m 前 · 用时 4m

立即运行

编辑

禁用

删除

隐藏运行记录

| 状态 | 开始                  | 时长 | 费用      | 轮次 | 触发        | 详情 |
|----|---------------------|----|---------|----|-----------|----|
| 成功 | 2026-08-25 04:08:38 | 4m | \$0.183 | 4  | scheduled | 收起 |

subtype success

is\_error false

stop\_reason end\_turn

num\_turns 4

total\_cost\_usd \$0.1827

session\_id c90d78ad-7bc7-4c66-9a6e-c5c8094c77e6

8



# 这一条是修出来的，不是一次就对

| 版本 | 结果         | 原因                                                          |
|----|------------|-------------------------------------------------------------|
| v1 | 失败，退出码 127 | <code>~/.local/bin/claude</code> 指向已失效的旧扩展；修好后又被 Bash 权限门阻断 |
| v2 | 成功         | 新 Agent 用受限 prompt，权限收成精确 allowlist                         |

v2 权限只给到 `Read, Grep, Glob, Bash(python3 qc.py *)` 及其绝对路径形式。

AI 只有提议权 (draft)，上膛必须人来点 —— 这不是我们设计的，是 Claudepot 写死的：CLI 里根本没有 `install` 这个动词。

最重要的一课：自述是元数据，产物才是证据。

## 还没做到的（不粉饰）与下一步

- 单轮串联：legacy `qc.py` 里复核能看到主审答案，做不到真正的三方盲判
- 多轮回源闭环：遇分歧反复回原文核实、三回合仍无共识才交人裁决 —— 尚未实现
- 带 frozen DIP manifest 的真实 audited production run —— 未完成

下一步：把单轮串联改造成多轮循环，逐轮把原始判断与证据落盘；跑通 DIP → QC 生产 run；给 Claudepot agent 配 cron 做到无人值守。

GitHub: <https://github.com/wangfeifei-321/qc-team>